











































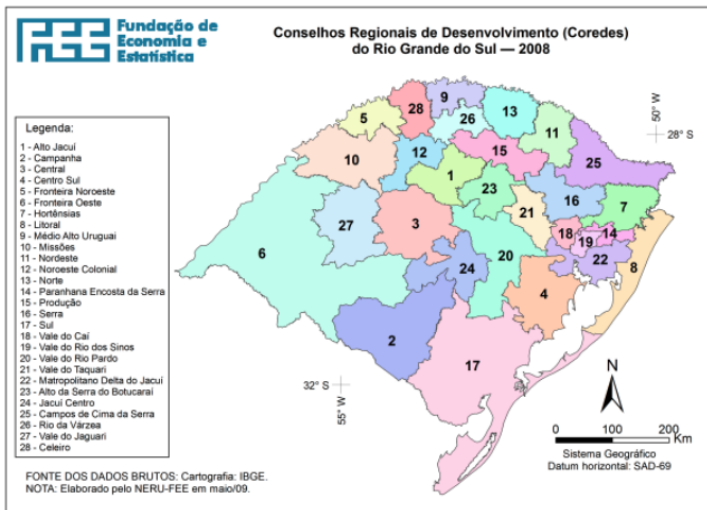








## COREDEs: Localização







## Grupos - COREDEs Agropecuários










## POERSCHKE, Rafael P.




## POERSCHKE, Rafael P.







## O Problema da ACP: abordagem geométrica















## Componentes Principais: abordagem geométrica

Após, procuramos por um segundo componente,  $\mathbf{u}_2^T \mathbf{X}$ , que não correlacionado com  $\mathbf{u}_1^T \mathbf{X}$  e tenha máxima variância, e assim sucessivamente até encontrarmos o  $k$ -ésimo estágio que possua máxima variância e ausência de correlação com  $\mathbf{u}_1^T \mathbf{X}, \mathbf{u}_2^T \mathbf{X}, \dots, \mathbf{u}_{k-1}^T \mathbf{X}$ .



## Componentes Principais: abordagem geométrica

Para derivarmos os Componentes Principais, consideremos um primeiro  $\mathbf{u}_1^\top \mathbf{X}$ ; o vetor  $\mathbf{u}_1$  maximiza  $\text{Var}(\mathbf{u}_1^\top \mathbf{X}) = \mathbf{u}_1^\top \mathbf{S}_X \mathbf{u}_1$ . Como foi supra-exposto,  $\mathbf{u}_i^\top \mathbf{u}_j = 1$  é assumido como restrição, e para solução fazemos uso do Lagrangiano.

Nesse sentido, temos o problema de otimização condicionada dado por

$$\begin{cases} \max_{\mathbf{u}_1 \in \mathbb{R}^p} & (\mathbf{u}_1^\top \mathbf{S}_X \mathbf{u}_1) \\ \text{sujeito a:} & \|\mathbf{u}_1\| = \mathbf{u}_1^\top \mathbf{u}_1 = 1. \end{cases} \quad (1)$$

Assim, para maximizar  $\mathbf{u}_1^T \mathbf{S}_X \mathbf{u}_1$  sujeito a  $\mathbf{u}_k^T \mathbf{u}_k = 1$ , significa maximizar

$$\mathcal{L}(\mathbf{S}, \mathbf{u}_1, \lambda_1) = \mathbf{u}_1^\top \mathbf{S}_X \mathbf{u}_1 - \lambda_1 (\mathbf{u}_1^\top \mathbf{u}_1 - 1),$$

onde  $\lambda_1 \in \mathbb{R}$  representa o multiplicador de Lagrange.







# Teorema de Lagrange

Efetuada a derivada, coordenada a coordenada, temos

$$\frac{\partial}{\partial u_1} (\mathbf{u}^T \mathbf{u}) = 2u_1;$$

$$\frac{\partial}{\partial u_2} (\mathbf{u}^T \mathbf{u}) = 2u_2;$$

$$\vdots$$

$$\frac{\partial}{\partial u_p} (\mathbf{u}^T \mathbf{u}) = 2u_p.$$

# Teorema de Lagrange

Montando o gradiente de  $g(\vec{x}_0)$  encontramos:

$$\nabla(\mathbf{u}^T \mathbf{u}) = [2u_1, 2u_2, \dots, 2u_p]$$

$$= 2[u_1, u_2, \dots, u_p]$$

$$\boxed{\nabla(\mathbf{u}^T \mathbf{u}) = 2\mathbf{u}}$$

# Teorema de Lagrange

Agora busca-se o  $\nabla f(\vec{x}_0)$  derivamos coordenada a coordenada:

$$\mathbf{u}^T \mathbf{S} \mathbf{u} = [u_1, u_2, \dots, u_p]_{1 \times p} \begin{bmatrix} \sigma_{11}^2 & \sigma_{12}^2 & \dots & \sigma_{1p}^2 \\ \sigma_{21}^2 & \sigma_{22}^2 & \dots & \sigma_{2p}^2 \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_{p1}^2 & \sigma_{p2}^2 & \dots & \sigma_{pp}^2 \end{bmatrix}_{p \times p} \begin{bmatrix} u_1 \\ u_2 \\ \vdots \\ u_p \end{bmatrix}_{p \times 1}$$

# Teorema de Lagrange

Então, iremos derivar coordenada a coordenada, mas se  $\mathbf{u}^T \mathbf{S} \mathbf{u} = \mathbf{u}^T \mathbf{W}$ , com  $\mathbf{W} = \mathbf{S} \mathbf{u}$ , precisamos aplicar a regra do produto em (0a), ou seja:

$$\frac{\partial}{\partial \mathbf{u}} (\mathbf{u}^T \mathbf{W}) = \mathbf{u}^T \frac{\partial \mathbf{W}}{\partial \mathbf{u}} + \mathbf{W}^T \frac{\partial \mathbf{u}}{\partial \mathbf{u}}$$

$$= \mathbf{u}^T \mathbf{S} + \mathbf{W}^T$$

$$= \mathbf{u}^T \mathbf{S} + \mathbf{u}^T \mathbf{S}^T$$

$$= \mathbf{u}^T (\mathbf{S} + \mathbf{S}^T).$$



# Teorema de Lagrange

Como  $\mathbf{S}$  é matriz de variância-covariância, portanto ela é simétrica ( $\mathbf{S} = \mathbf{S}^T$ ), logo:

$$\frac{\partial}{\partial u_1}(\mathbf{u}^T \mathbf{S} \mathbf{u}) = 2 \sum_{j=1}^p \sigma_{1j}^2 u_j$$

$$\frac{\partial}{\partial u_2}(\mathbf{u}^T \mathbf{S} \mathbf{u}) = 2 \sum_{j=1}^p \sigma_{2j}^2 u_j$$

$$\vdots$$

$$\frac{\partial}{\partial u_p}(\mathbf{u}^T \mathbf{S} \mathbf{u}) = 2 \sum_{j=1}^p \sigma_{pj}^2 u_j$$

$$\frac{\partial}{\partial \mathbf{u}}(\mathbf{u}^T \mathbf{S} \mathbf{u}) = 2\mathbf{S}\mathbf{u}$$

# Componentes Principais: abordagem geométrica

**UFA! Agora sim podemos seguir!**

$$\mathcal{L}(\mathbf{S}, \mathbf{u}_1, \lambda_1) = \mathbf{u}_1^T \mathbf{S}_X \mathbf{u}_1 - \lambda_1 (\mathbf{u}_1^T \mathbf{u}_1 - 1),$$

Diferenciando com respeito a  $\mathbf{u}_1$ , temos

$$2\mathbf{S}_X \mathbf{u}_1 - 2\lambda_1 \mathbf{u}_1 = 0$$

$$\mathbf{S}_X \mathbf{u}_1 = \lambda_1 \mathbf{u}_1$$

ou seja,

$$(\mathbf{S}_X - \lambda_1 \mathbf{I}_p) \mathbf{u}_1 = 0,$$

tal que  $\mathbf{I}_p$  é a matriz identidade de dimensão  $p \times p$ . Então,  $\lambda_1$  é um autovalor de  $\mathbf{S}_X$  e  $\mathbf{u}_1$  o seu autovetor correspondente.

# Autovalor: o nosso $\lambda^3$

A matriz  $\mathbf{A} \in \mathbf{M}_{n \times n}(\mathbb{R})$  possui um autovalor  $\lambda \in \mathbb{C}$  se, e somente se, existe um vetor  $\underbrace{\mathbf{e}}_{(n \times 1)}$  não nulo tal que,  $\mathbf{A}\mathbf{e} = \lambda\mathbf{e}$ . Nesse caso,

dizemos que  $\lambda$  é um autovalor associado ao autovetor  $\mathbf{e}$ .

Portanto, o problema de encontrar autovalores de uma matriz se reduz na procura pelas raízes de um certo polinômio em  $\lambda$ , denominado polinômio característico. Mais explicitamente,

$$\begin{aligned}\mathbf{A}\mathbf{e} = \lambda\mathbf{e} &\iff \mathbf{A}\mathbf{e} - \lambda\mathbf{e} = \mathbf{0} \\ &\iff (\mathbf{A} - \lambda\mathbf{I})\mathbf{e} = \mathbf{0}\end{aligned}\tag{3}$$

---

<sup>3</sup>HOFFMAN, Kenneth; KUNZE, Ray. **Linear Algebra**, Englewood Cliffs. 1961.

# Autovalor: o nosso lambda

$$(\mathbf{A} - \lambda \mathbf{I})\mathbf{e} = 0$$

como  $\mathbf{e} \neq 0$  o sistema  $[\mathbf{A} - \lambda \mathbf{I}]\mathbf{e} = 0$  possui solução não nula se, e somente, se

$$\det(\mathbf{A} - \lambda \mathbf{I}) = 0 \quad (4)$$

tal que:  $\mathbf{A} = \lambda_1 \mathbf{e}_1 \mathbf{e}_1^T + \lambda_2 \mathbf{e}_2 \mathbf{e}_2^T + \cdots + \lambda_k \mathbf{e}_k \mathbf{e}_k^T$ <sup>4</sup>

---

<sup>4</sup>Conhecida como Decomposição Espectral, que pode ser escrita também como:  $\sum_{i=1}^k \lambda_i \mathbf{e}_i \mathbf{e}_i^T = \mathbf{P} \mathbf{\Lambda} \mathbf{P}^{-1}$ , tal que  $\mathbf{\Lambda}$  é uma matriz diagonal de autovalores de  $\mathbf{A}$ . Por definição, uma matriz diagonal é uma matriz quadrada que possui todos os elementos acima e abaixo da diagonal principal nulos.

# Autovalor: o nosso lambda

**Definição:** Seja  $V$  um espaço vetorial sobre o campo  $F$  e  $T$  um operador linear em  $V$  tal que  $T : V \rightarrow V$ . Um **autovalor** de  $T$  é um escalar  $\lambda$  em  $F$  tal que existe um vetor **não-nulo**<sup>5</sup>  $\mathbf{e} \in V$  com  $T\mathbf{e} = \lambda\mathbf{e}$ . Se  $\lambda$  é um autovalor de  $T$ , então

1. Qualquer  $\mathbf{e}$  tal que  $T\mathbf{e} = \lambda\mathbf{e}$  é chamado de **autovetor** de  $T$  associado ao autovalor  $\lambda$ ;
2. A coleção de todos os  $\mathbf{e}$  tais que  $T\mathbf{e} = \lambda\mathbf{e}$  é chamada de **espaço característico associado** a  $\lambda$ .

---

<sup>5</sup>O vetor nulo não pode estar no espaço nulo de  $T$ . **Espaço Nulo**  $\mathcal{N}(T) \in R^m$ : é o conjunto de todas as soluções para o sistema  $Ax = 0$ . O núcleo de uma transformação linear ( $Ker(T)$ ) é sinônimo, isto é,  $Ker(T) = \{\mathbf{e} \in V : T\mathbf{e} = 0\}$ . Ambos se referem ao conjunto de vetores do domínio que são mapeados para o vetor nulo no contradomínio pela transformação linear.

# Autovalor: o nosso lambda

## Autovalores:

Os **autovalores** são frequentemente chamados: valores característico, raízes características, raízes latentes, valores próprios ou valores espectrais.

# Autovalor: o nosso lambda

Se  $\mathbf{T}$  é qualquer operador linear e  $\lambda$  é qualquer escalar, o conjunto de vetores  $\mathbf{e}$  tal que  $\mathbf{T}\mathbf{e} = \lambda\mathbf{e}$  é um subespaço de  $V$ .

$$(\mathbf{T} - \lambda\mathbf{I}) \text{ é não injetiva} \iff \exists \mathbf{v}_1, \mathbf{v}_2 : \mathbf{v}_1 \neq \mathbf{v}_2 \text{ e } (\mathbf{T} - \lambda\mathbf{I})\mathbf{v}_1 = (\mathbf{T} - \lambda\mathbf{I})\mathbf{v}_2$$

$$\iff \exists \mathbf{x} : \mathbf{x} \neq 0 \text{ e } (\mathbf{T} - \lambda\mathbf{I})\mathbf{x} = 0$$

$$\iff (\mathbf{T} - \lambda\mathbf{I}) \text{ é singular}$$

$$\iff \det(\mathbf{T} - \lambda\mathbf{I}) = 0$$

# Autovalor: o nosso lambda

Se  $(\mathbf{T} - \lambda \mathbf{I})$  é não-singular, note que em

$(\mathbf{T} - \lambda \mathbf{I})\mathbf{x} = 0$ , podemos multiplicar pela inversa

$$(\mathbf{T} - \lambda \mathbf{I})^{-1}(\mathbf{T} - \lambda \mathbf{I})\mathbf{x} = (\mathbf{T} - \lambda \mathbf{I})^{-1} 0$$

$$\mathbf{I}\mathbf{x} = 0 \implies \mathbf{x} = 0$$

Exatamente o que não queremos.









# Componentes Principais: abordagem geométrica

Para decidirmos qual dos  $p$  autovetores produz  $\mathbf{u}_1^T$  de máxima variância, note que a quantidade a ser maximizada é

$$\mathbf{u}_1^T \mathbf{S}_X \mathbf{u}_1 = \mathbf{u}_1^T \lambda_1 \mathbf{u}_1 = \lambda_1 \mathbf{u}_1^T \mathbf{u}_1 = \lambda_1,$$

assim,  $\lambda_1$  deve ser o maior possível. Logo,  $\mathbf{u}_1$  é o autovetor associado ao maior autovalor de  $\mathbf{S}_X$ , e

$$\text{Var}(\mathbf{u}_1^T \mathbf{S}_X \mathbf{u}_1) = \mathbf{u}_1^T \lambda_1 \mathbf{u}_1 = \lambda_1. \text{ Então, } \lambda_1 = \text{Var}(\mathbf{w}_1) > 0.$$



# Componentes Principais: abordagem geométrica

Assim, cada dessas equações

$$\mathbf{u}_1^T \mathbf{S}_X \mathbf{u}_2 = 0$$

$$\mathbf{u}_2^T \mathbf{S}_X \mathbf{u}_1 = 0$$

$$\mathbf{u}_1^T \mathbf{u}_2 = 0$$

$$\mathbf{u}_2^T \mathbf{u}_1 = 0$$

pode ser usada para indicar ausência de correlação entre  $\mathbf{u}_1^T \mathbf{X}$  e  $\mathbf{u}_2^T \mathbf{X}$ . Assumimos igualmente a hipótese de normalização entre  $\mathbf{u}_1^T \mathbf{X}$  e  $\mathbf{u}_2^T \mathbf{X}$ , a quantidade que deve ser maximizada será

$$\mathcal{L}(\mathbf{S}, \mathbf{u}_1, \mathbf{u}_2, \lambda_2, \phi) = \mathbf{u}_2^T \mathbf{S}_X \mathbf{u}_2 - \lambda_2 (\mathbf{u}_2^T \mathbf{u}_2 - 1) - \phi \mathbf{u}_2^T \mathbf{u}_1,$$

onde  $\lambda_2$  e  $\phi$  são os multiplicadores de Lagrange.



## Componentes Principais: abordagem geométrica

Além disso,  $\mathbf{S}_X \mathbf{u}_2 - \lambda_2 \mathbf{u}_2 = 0$ , ou equivalente a  $(\mathbf{S}_X - \lambda_2 \mathbf{I}_p) \mathbf{u}_2 = 0$ , então  $\lambda_2 = \text{Var}(\mathbf{w}_2)$ , e desde que os autovalores de  $\mathbf{S}_X$  são distintos,  $\lambda_2$  é o autovalor de  $\mathbf{S}_X$ , e  $\mathbf{u}_2$  representa seu autovetor correspondente.























